

DESCRIPTIVO EJECUTIVO

Forecasting de ventas de consumo masivo

El recorrido que hice hasta elegir el modelo final

Autora: Noelia Carolina Ramirez Paredez

Materia: Laboratorio 3 · Maestría en Ciencia de Datos

Qué quería resolver

El desafío era pronosticar cuántas toneladas se venderían de cada producto en febrero de 2020, utilizando únicamente la información disponible hasta diciembre de 2019. Para comparar las distintas alternativas utilice WAPE agregado por producto, la misma métrica de la competencia.

Cómo trabajé

Primero armé una base enriquecida a nivel cliente–producto–período. Cuando un cliente no compraba un producto en un mes determinado, incorporé esa observación con venta igual a cero. Así obtuve un panel de aproximadamente 17,17 millones de registros que representa tanto las compras como los períodos de inactividad.

A partir de esa base probé alternativas muy diferentes: baselines, regresión lineal y Ridge, AutoARIMA, AutoGluon y varias versiones de LightGBM. Con cada iteración fui entendiendo que mix de modelos podría llegar ser más adecuado. El resultado más consistente apareció al conservar el detalle cliente–producto, agrupar las series por comportamientos similares y combinar modelos especializados con una mirada agregada por producto.

Qué aprendí en el camino

Etapas	Hipótesis analizada	Resultado
Modelos iniciales	Baselines, AutoARIMA, AutoGluon y regresión	El resultado fue competitivo
v2–v10	Clusters, especialistas y ensambles multisevilla	La granularidad cliente–producto fue la más efectiva
v11 / v11.1	Variables de clientes y estacionalidad	Mayor estabilidad, sin mejora del score
v12	Modelo producto–período	Perdió información de composición de clientes
v10.4	Ridge para nivel + LightGBM residual	Aportó diversidad, pero no superó al campeón

Cómo quedó armado el modelo final

La versión elegida, v10.1, no depende de un único modelo. Está formada por dos ramas LightGBM y utiliza tres semillas: 109903, 109927 y 203999. Primero se promediaron las predicciones obtenidas con las tres semillas dentro de cada rama y luego combine ambos resultados con pesos 75/25.

Componente	Entrenamientos	Participación
v3 · cliente–producto por 6 clusters	6 clusters × 3 semillas = 18 LightGBM	75%
v4 · modelo agregado producto–período	1 modelo × 3 semillas = 3 LightGBM	25%
Ensemble final	21 ajustes LightGBM	75% v3 + 25% v4

La rama v3 mira el problema con más detalle: asigna cada serie cliente–producto a uno de seis clusters y entrena un modelo de LightGBM independiente para cada tipo de comportamiento. Además, combina su resultado con una referencia interanual según el peso validado para cada grupo. La rama v4 trabaja a nivel producto–período y funciona como una mirada más general, ayudando a estabilizar la predicción. En total, el ensemble reúne 21 ajustes LightGBM.

Cómo rindieron las versiones

Versión	WAPE público	Decisión
v10.2	0,230	Descartada por leakage indirecto
v10.1	0,231	Modelo final seleccionado
v10.4 · 75/25	0,233	Descartada
v10.4 · 90/10	0,233	Descartada
v11.1	0,237	Descartada
v12	0,295	Descartada

Por qué no elegí el mejor score

La v10.2 alcanzó 0,230 y, a primera vista, parecía ser la mejor versión. Sin embargo, al revisar el proceso con más detalle detecte información futura indirecta: el screening evaluaba períodos históricos usando clusters contruidos con meses posteriores y algunas filas podían depender de la última venta conocida. Aunque la diferencia de score era pequeña, preferí no presentar un resultado que no pudiera defender metodológicamente.

Con qué modelo nos quedamos

Finalmente elegí la v10.1, que obtuvo un WAPE público de 0,231. El score quedó apenas por encima del 0,230 de v10.2, pero esta versión mantuvo la granularidad cliente–producto, utilizó nuestras semillas, generó una submission completa y no presentó los problemas temporales encontrados en la versión siguiente.

En síntesis: no elegí simplemente el número más bajo. Me quede con el mejor resultado que pude reproducir, explicar y defender con tranquilidad.